

Proyecto segmentación por instancias



Integrantes:

Niko Alejandro Bonilla Martinez

David Alejandro Perez

Facultad de Ingeniería y Ciencias Básicas, Universidad Autónoma de Occidente

Procesamiento digital de imágenes

Docente. Nicolas Llanos Neuta

26 de Mayo de 2026

Tabla de contenido

1. Portada	1
2. Tabla de contenido	2
3. Introducción	3
4. justificación del problema	3
5. Marco teórico	4
5.1. Urbanización, microclima y cambio climático	4
5.2 Zonas Climáticas Locales (ZCL) y morfología urbana	4
5.3 El factor de visión del cielo (FVC)	5
4. Iluminación natural, confort y bienestar urbano	5
6. descripción de la arquitectura	5
6.1. Elección del modelo: YOLOv8-Seg	6
6.2. Funcionamiento general de YOLOv8-Seg	6
6.3. Flujo de segmentación aplicado al cálculo del FVC	7
6.4. Diagrama conceptual de la arquitectura	8
6.5. Generación de etiquetas mediante Roboflow	9
7. Metodología	9
7.1 Proceso de captura de imágenes	9
7.2. Preprocesamiento de datos	10
8. pipeline implementado	10
9. Resultados cuantitativos y cualitativos	12
9.1 Resultados cuantitativos	12
9.2. Análisis Cualitativo	13
10. Conclusiones	13
11. posibles mejoras	14
12. Referencias	16

3. Introducción

En los últimos años los cambios de usos del suelo, de morfología y de materiales del ambiente construido son algunos de los resultados de los procesos de urbanización causados por el aumento de población urbana y considerados incidentes en el cambio climático. Actualmente, más de la mitad de la población mundial reside en zonas urbanas, una tasa que se prevé alcance el 70 % en 2050[5]. El entorno edificado y el contexto urbano influyen sobre el microclima local, sobre los consumos de energía y sobre el bienestar de los habitantes de la ciudad. Esto se ha visto reflejado en el aumento de temperatura y de ondas de calor. Debido a la influencia negativa de la isla de calor urbana (ICU), los entornos térmicos urbanos deficientes se han convertido en un problema urgente de sostenibilidad. Numerosos estudios han intentado proponer estrategias de mitigación mediante la investigación de factores relevantes de diseño y planificación. Uno de los factores de diseño más estudiados es el factor de visión del cielo (SVF).

Desde este punto de vista, en las zonas urbanas densamente construidas de la universidad Autónoma de Occidente, la cantidad de cielo visible es entre las 2 p.m. y las 5 p.m. influye en la ventilación natural, la entrada de luz solar y la sensación de apertura ambiental.

Este proyecto busca aplicar segmentación por instancias para identificar las áreas del cielo y las estructuras urbanas (edificios, postes, árboles, techos) en imágenes de la Universidad Autónoma de Occidente. El resultado permitirá calcular el porcentaje de cielo visible en cada entorno y analizar su relación con la densidad urbana y el confort ambiental.

4. justificación del problema

El factor de visión del cielo (SVF, por sus siglas en inglés) juega un papel crucial en la configuración del clima urbano y la calidad del aire, especialmente en entornos densamente construidos.

Una observación común es que las zonas con un bajo factor de ventilación superficial (FVS), como calles estrechas y patios interiores, tienden a retener el calor, contribuyendo al efecto isla de calor urbana (ICU), donde las ciudades permanecen más cálidas que las zonas rurales circundantes.

Estos espacios retienen el calor durante la noche, ralentizando el proceso natural de enfriamiento y agravando el malestar térmico. En contraste, las zonas con un FVS más alto permiten una mejor disipación del calor y ventilación natural, lo que facilita una regulación más eficaz de las temperaturas.

5. Marco teórico

5.1. Urbanización, microclima y cambio climático

La urbanización se caracteriza por una baja densidad de vegetación, una alta proporción de superficies impermeables, una elevada rugosidad (debido al tamaño y la altura de los edificios) y un mayor consumo energético. Estas características particulares afectan al clima de las zonas urbanas. En comparación con el clima rural, el microclima urbano presenta un menor flujo de calor por evaporación, una mayor retención de radiación de onda corta y larga, una menor ventilación y una mayor cantidad de calor liberado a la atmósfera. Como resultado, la temperatura suele ser más alta en las zonas urbanas que en las zonas rurales circundantes. Este fenómeno se denomina isla de calor urbana (ICU) y puede afectar al confort en exteriores.[4]

Debido a que se han intensificado las olas de calor debido al cambio climático existe una necesidad urgente de mitigar el fenómeno de isla de calor urbana. Se han investigado y probado diversas técnicas en todo el mundo: vegetación en techos, fachadas y suelos; pintura de techos y paredes para modificar la absorción de radiación tanto en el espectro de onda corta como en el de onda larga; soluciones basadas en agua, como fuentes o aspersores; optimización de la densidad y orientación de los edificios para generar sombra.[4]

5.2 Zonas Climáticas Locales (ZCL) y morfología urbana

La capacidad de las estrategias de reducción del fenómeno de isla de calor urbana, depende del contexto climático y morfológico. Stewart introdujo el término Zonas Climáticas Locales (ZCL) para clasificar y evaluar los ambientes urbanos, las cuales distinguen los tipos de construcciones y coberturas del suelo en función de parámetros geométricos y de cobertura del suelo. El Factor de Visión del Cielo (FVC) es uno de estos parámetros. Esta se consiste de una variable geométrica que determina la parte del hemisferio que se puede ver desde la superficie terrestre, si no hay obstáculos como edificios, terreno o árboles.

5.3 El factor de visión del cielo (FVC)

El factor de visión del cielo es un parámetro vital, que se utiliza para medir el intercambio energético de la radiación entre la ciudad y la atmósfera. Se trata de un fenómeno extremadamente vinculado a la temperatura superficial, y condiciona la isla de calor urbano.[6]

En estudios recientes se implementaron herramientas de cálculo del FVC en entornos SIG, como OrbisGIS y SAGA-GIS, que permiten determinar este factor a partir de modelos vectoriales. En una investigación desarrollada en París, se compararon ambos algoritmos sobre 72 manzanas urbanas representativas de diferentes tipos de edificación de las Zonas Climáticas Locales. Los resultados demostraron una desviación estándar de 0,03 en la estimación del FVC medio por manzana y una relación lineal significativa entre el FVC y la densidad de fachadas, lo cual confirma la relación directa entre morfología urbana y exposición al cielo[4].

4. Iluminación natural, confort y bienestar urbano

En cuanto a la habitabilidad de los barrios urbanos, la iluminación natural, especialmente la luz diurna, es un factor esencial[7], relacionado con el FVC, dado que muchos investigadores han señalado la luz natural como un factor psicológico óptimo para la vida, ya que los primeros seres humanos identificaron el Sol como su única fuente de luz y vivieron bajo la luz del día. Además de los efectos psicológicos, especialmente durante una tarea, una iluminación agradable siempre se valora y se relaciona con el confort y el rendimiento humanos, pero resulta imposible establecer una relación objetiva entre la luz y la productividad, dado que influyen muchas otras variables como el ruido, la calidad del aire y la temperatura. Las personas tienen una tendencia instintiva a preferir la luz natural a los espacios iluminados artificialmente en un edificio, y diversos estudios han confirmado que la exposición a la luz natural puede tener un efecto significativo en el bienestar, disminuyendo dolores de cabeza, fatiga ocular y estrés[8].

6. descripción de la arquitectura

Para el desarrollo de este proyecto se utilizó YOLOv8, que es una arquitectura de modelo de visión por computadora que se puede utilizar para tareas de detección de objetos, clasificación de imágenes y segmentación de instancias[9]. Para este caso, se empleó la variante YOLOv8-Seg (segmentación por instancias), la que en lugar de simplemente identificar y delimitar objetos, segmenta con precisión los píxeles de cada objeto individual, delineando eficazmente su forma y aislándolo del fondo[10].

6.1. Elección del modelo: YOLOv8-Seg

La segmentación de YOLOv8 aprovecha las fortalezas de su contraparte de detección de objetos, destacando:

- Alta precisión: Ofrece un rendimiento de vanguardia en la segmentación de diversos objetos, incluidos aquellos de diferentes tamaños, muy próximos y en poses difíciles.
- Capacidades en tiempo real: Las velocidades de inferencia siguen siendo impresionantes, lo que lo hace adecuado para aplicaciones del mundo real que requieren un procesamiento rápido.
- Tamaño compacto del modelo: Los modelos son relativamente pequeños, lo que permite su implementación en dispositivos con recursos computacionales limitados.
- API fácil de usar: El framework Ultralytics proporciona una API simple e intuitiva para una fácil integración en diversos proyectos.

6.2. Funcionamiento general de YOLOv8-Seg

El primer paso para comprender la arquitectura de YOLO es entender que el algoritmo consta de tres bloques esenciales: Backbone, Neck y Head, donde se desarrolla toda la operación. La función de cada bloque se describe a continuación.

1. Backbone

- Función: La columna vertebral, también conocida como extractor de características, se encarga de extraer las características relevantes de la entrada.
- Actividades:
 - Captura patrones simples en las capas iniciales, como bordes y texturas.
 - Permite múltiples escalas de representación a medida que se avanza, capturando características de diferentes niveles de abstracción.
 - Proporciona una representación jerárquica y detallada de la entrada.

2. Neck

- Función: El cuello actúa como puente entre la columna vertebral y la cabeza, realizando operaciones de fusión de características e integrando información contextual. Básicamente, el cuello ensambla pirámides de características agregando mapas de características obtenidos por la columna vertebral; es decir, el cuello recopila mapas de características de diferentes etapas de la columna vertebral.
- Actividades:
 - Realiza la concatenación o fusión de características de diferentes escalas para asegurar que la red pueda detectar objetos de diferentes tamaños.
 - Integra información contextual para mejorar la precisión de la detección al considerar el contexto más amplio de la escena.
 - Reduce la resolución espacial y la dimensionalidad de los recursos para facilitar el cálculo, lo cual aumenta la velocidad pero también puede reducir la calidad del modelo.

3. Head

- Función: El nodo de control es la parte final de la red y se encarga de generar sus salidas, como los recuadros delimitadores y los índices de confianza para la detección de objetos.
- Actividades:
 - Genera recuadros delimitadores asociados a los posibles objetos en la imagen.
 - Asigna un índice de confianza a cada recuadro delimitador para indicar la probabilidad de que un objeto esté presente.
 - Clasifica los objetos dentro de los recuadros delimitadores según sus categorías.

6.3. Flujo de segmentación aplicado al cálculo del FVC


1. Entrada de la imagen urbana capturada en zonas abiertas de la Universidad Autónoma de Occidente.
2. YOLOv8-Seg identifica todas las instancias presentes.
3. Se extrae automáticamente la clase “Cielo”.
4. Se genera la máscara en escala binaria:
 - 0 → píxeles pertenecientes al cielo
 - 1 → otros elementos urbanos
5. Se calcula el Factor de Visión del

Cielo: $SVF = \frac{\text{Número de píxeles de cielo}}{\text{Número total de píxeles de la imagen}}$

Número de píxeles de cielo

Número total de píxeles de la imagen

6.4. Diagrama conceptual de la arquitectura



6.5. Generación de etiquetas mediante Roboflow

Para entrenar de manera apropiada un modelo de segmentación como YOLOv8-Seg, es necesario tener máscaras exactas que señalen a qué clase pertenecen cada uno de los píxeles. La creación manual de estas etiquetas supone un procedimiento que es lento, subjetivo y difícil de ampliar. Por esta razón, la plataforma Roboflow se empleó como instrumento de etiquetado en el presente proyecto, dado que facilita la creación y organización de las máscaras de segmentación requeridas de forma eficaz, exportándolas directamente en un formato que YOLOv8-Seg puede usar.

7. Metodología

7.1 Proceso de captura de imágenes

Se llevó a cabo la recolección de datos en las áreas públicas del campus de la Universidad Autónoma de Occidente, incluyendo espacios tales como pasillos para peatones, plazas y zonas verdes. Fueron elegidas estas ubicaciones debido a que muestran diferentes configuraciones geométricas y niveles variados de apertura del cielo, lo que es apropiado para el estudio del Factor de Visión del Cielo (FVC).

Las fotografías se obtuvieron con un teléfono móvil, que fue posicionado siempre en posición vertical y con una perspectiva enfocada hacia las fachadas, construcciones y el cielo de alrededor. La segmentación es relevante en esta franja horaria, que va desde las 2:00 p.m. hasta las 5:00 p.m., y que se caracteriza por la fuerte iluminación solar y el marcado contraste de sombras urbanas.

Para la tarea de segmentación por instancias, se recopiló un total de 150 imágenes para la clase "Estructuras" y 120 imágenes para la clase "Cielo", asegurando así un equilibrio apropiado.

7.2. Preprocesamiento de datos

Se realizaron diferentes fases de preprocesamiento para asegurar que el modelo YOLOv8-Seg sea compatible correctamente:

- **Redimensionamiento**

Para alcanzar el máximo rendimiento en la formación, todas las imágenes se transformaron a una resolución de 640×640 píxeles, conforme a lo sugerido por Ultralytics.

- **División del dataset**

La distribución de datos fue la siguiente: 80% para el entrenamiento, 10% para test y 10% para validación, asegurando que ambas clases principales se distribuyeran de manera uniforme.

- **Normalización y organización**

Según el formato estándar de YOLOv8-Seg, las imágenes fueron transformadas al espacio RGB normalizado y organizadas en carpetas: valid, test y train, cada una con sus carpetas imágenes y labels. Se garantizó la consistencia entre las imágenes y sus anotaciones al asociar correctamente cada máscara producida por Roboflow con su archivo de texto correspondiente.

- **Reducción de ruido**

Se utilizó un filtro gaussiano en cada imagen con el objetivo de disminuir el ruido y atenuar las pequeñas variaciones de intensidad, sin poner en riesgo los bordes significativos de los objetos, sobre todo las estructuras urbanas y el cielo, para optimizar la calidad de las imágenes y simplificar la segmentación.


8. pipeline implementado

El proceso de este proyecto abarca todas las fases requeridas para examinar y calcular el Factor de Visión del Cielo (SVF) en áreas urbanas dentro del campus de la Universidad Autónoma de Occidente. Para segmentar por instancias de manera apropiada, se llevó a cabo primero la captura de imágenes en áreas verdes, plazoletas y pasajes peatonales, mediante un teléfono móvil entre las 2:00pm y las 5:00pm. Se obtuvieron 150 imágenes de estructuras y 120 de cielo.

Posteriormente, se utilizó la plataforma Roboflow para generar etiquetas que facilitaron la elaboración de máscaras ordenadas y precisas para cada clase en el formato compatible con YOLOv8-Seg. Después, se realizó un preprocesamiento de todas las imágenes que incluyó: el redimensionamiento a 640×640 píxeles, la normalización RGB, la disposición en carpetas llamadas valid, test y train, cada una con sus carpetas imágenes y labels, respetando la norma de YOLO, y la utilización de un filtro gaussiano para disminuir el ruido sin alterar los bordes de los objetos. El 80% del conjunto de datos se utilizó para el entrenamiento, mientras que el 10% fue destinado a la validación y otro 10% al test.

Con el dataset preparado, se entrenó y configuró el modelo YOLOv8-Seg, a partir de hiperparámetros sugeridos por Ultralytics. Estos incluían 40 épocas, un tamaño de batch de 8 y una resolución de 640 × 640 píxeles.

Durante la fase de inferencia, se utilizó el modelo entrenado en imágenes recientes del campus, produciendo máscaras divididas para las estructuras y el cielo. Se procesaron estas máscaras con el fin de determinar la cantidad de píxeles que pertenecen al cielo y a la imagen completa, para así conseguir el SVF. Este índice posibilita valorar la apertura del cielo y su vínculo con la densidad urbana y el confort ambiental. Por último, se produjeron visualizaciones que exhiben la imagen original, la máscara del cielo y una superposición con el porcentaje de cielo detectado, lo cual simplifica la comprensión de los resultados y su aplicación en investigaciones de microclima urbano.



9. Resultados cuantitativos y cualitativos

9.1 Resultados cuantitativos

Métrica	Valor Derivado	Interpretación
Precisión (M)	0.621	Evalúa la proporción de las segmentaciones positivas del modelo que son precisas. Un valor de 0.621 es positivo y señala que el modelo acierta la mayor parte del tiempo cuando segmenta estructuras o cielo, reduciendo los falsos positivos.
Recall (M)	0.660	El modelo identificó y segmentó el 66% de todos los casos reales existentes. Un valor moderado indica que existen casos de cielo o estructura que el modelo todavía no puede identificar de manera consistente.
F1-Score (M)	~0.640	Calcula la media armónica de la precisión y el recall. El modelo mantiene un equilibrio sólido entre ser exhaustivo en la detección de instancias y ser preciso en su clasificación, lo que se confirma con el valor 0.640.
mAP@50 (Mask)	0.605	Valida que la segmentación es precisa.
mAP@50-95 (Mask)	0.397	Muestra la dificultad del modelo para segmentar con alta precisión los límites, siendo la principal limitación técnica.
Tiempo Total de Entrenamiento	127 minutos (40 épocas)	Métrica de Costo Computacional.
Tiempo de Inferencia por Imagen	~15 ms	Métrica de Despliegue en Tiempo Real. Un tiempo de 15 ms por imagen (66 FPS) indica que el modelo es apto para el procesamiento en tiempo real, lo cual es esencial para cumplir con el requisito de la aplicación interactiva sobre video o cámara.

9.2. Análisis Cualitativo

El resultado cualitativo central del proyecto es la generación de la máscara de segmentación y el cálculo derivado del Factor de Visión del Cielo (SVF).

1. Segmentación eficaz: El modelo muestra una habilidad funcional para diferenciar las dos clases, Cielo y Estructuras, creando máscaras exactas, aun en imágenes que contienen numerosas instancias de estructuras urbanas.
2. Medición derivada esencial: El cálculo del SVF, al ser implementado, transforma la salida de la Visión por Computadora en una métrica de sostenibilidad medioambiental que puede medirse. La función `visualizar_svf` proporciona un valor numérico inmediato para evaluar la apertura urbana, ya que calcula el porcentaje de cielo segmentado en relación con el total de píxeles.

10. Conclusiones

El proyecto ha evidenciado que la implementación de arquitecturas de segmentación por instancias innovadoras, como YOLOv8-Seg, para el desarrollo de métricas esenciales en términos de sostenibilidad urbana es factible y eficaz.

Meta principal alcanzada: Se consiguió crear un pipeline operativo que, utilizando imágenes urbanas del campus de la UAO, reconoce y segmenta las zonas de cielo y los edificios a su alrededor. El Factor de Visión del Cielo (SVF) es una variable geométrica fundamental en la investigación del microclima urbano y en la reducción del fenómeno de Isla de Calor Urbana (ICU); su cálculo es el resultado inmediato de esta segmentación.

Rendimiento funcional sólido: El modelo alcanzó un $mAP@50$ de 0.605, un valor que confirma su capacidad para generar máscaras espacialmente coherentes y adecuadas para el cálculo de cobertura. Este desempeño valida la metodología de creación de un *dataset* propio y el proceso de preprocesamiento adoptado, incluyendo el uso justificado del Filtro

Gaussiano para mitigar el ruido y mejorar la detección de bordes bajo condiciones de luz solar intensa.

Conexión con la sostenibilidad: El SVF calculado proporciona un instrumento cuantitativo para establecer una correlación entre la apertura ambiental y la densidad de construcción con el confort térmico. Esto posibilita que los planificadores de las ciudades detecten eficazmente las áreas críticas que necesitan estrategias para mitigar el calor (como techos verdes o más vegetación) con el fin de aumentar la calidad de vida de los residentes.

11. posibles mejoras

Para llevar este proyecto a un nivel de implementación profesional y mejorar su precisión técnica, se identifican las siguientes áreas de mejora:

Mejora del Rendimiento

- **Arquitectura y aumento de épocas:** Aumentar el entrenamiento a 100 o 200 épocas y pensar en emplear una arquitectura YOLOv8 de mayor tamaño (por ejemplo, yolov8l-seg.pt) para otorgarle al modelo más capacidad de representación e intentar así incrementar el mAP@50-95. Esto es esencial para mejorar la segmentación en los bordes difusos y estrechos.
- **Incremento y diversificación del conjunto de datos:** Para aumentar la capacidad de generalización del modelo, incluir fotografías tomadas en condiciones climáticas y horarias variadas (por ejemplo, durante la mañana o el atardecer y en días nublados) y multiplicar considerablemente la cantidad de imágenes.

Expansión de Clases y Análisis Urbano

Ajuste de clases: Agregar una tercera asignatura obligatoria (Árboles/Vegetación). La segmentación de la vegetación es esencial para el SVF porque, a pesar de que dificulta ver el cielo, ayuda a reducir la ICU por medio de la evapotranspiración. Esto posibilitará un análisis térmico más detallado.

Evaluación diferencial de materiales: Si el grupo lo permite, se pueden incluir clases como Techo Metálico o Muro de Concreto para clasificar con exactitud los materiales de alta y baja emisividad, mejorando así el análisis térmico.

12. Referencias

- [1] C. Carrasco, M. Palme, and M. Á. Gálvez. FACTOR DE CIELO VISIBLE Y EL EFECTO ISLA DE CALOR EN VALPARAISO. Universidad del Bío Bío. 2016.
<https://www.redalyc.org/journal/198/19849706004/html/#:~:text=Un%20menor%20cielo%20visible%20y,microclimas%20en%20los%20espacios%20urbanos>

- [2] J. Zhang, Z. Gou, Y. Lu, P. Lin. El impacto del factor de visión del cielo en los ambientes térmicos de los parques urbanos de una ciudad costera subtropical de Australia. Silvicultura urbana y ecologización urbana. 2019.
<https://www.sciencedirect.com/science/article/abs/pii/S1618866719302134#:~:text=Los%20efectos%20t%C3%A9rmicos%20de%20los.ambientes%20t%C3%A9rmicos%20de%20un%20parque>.
- [3] A. Ramachandran. El factor de visión del cielo (SVF) y su papel en el clima urbano. oneclicklca. 2025.
<https://oneclicklca.com/en/resources/articles/sky-view-factor-urban-climate-envi-met>
- [4] J. Bernard, E. Bocher, G. Petit, S. Palominos. Cálculo del factor de visión del cielo en contexto urbano: Análisis del rendimiento computacional y la precisión de dos herramientas SIG abiertas y gratuitas. MDPI. 2018.
<https://www.mdpi.com/2225-1154/6/3/60>
- [5] Objetivo 11: Lograr que las ciudades sean más inclusivas, seguras, resilientes y sostenibles. Naciones Unidas. 2023. M. Moran, "Ciudades - Desarrollo sostenible," Desarrollo Sostenible, Jan. 26, 2024.
<https://www.un.org/sustainabledevelopment/es/cities/>
- [6] R. Solé, "Sky View Factor o cuánto calor pasarás según el espacio entre fincas," Tiempo.com | Meteored, May 17, 2022.
<https://www.tiempo.com/noticias/ciencia/que-es-el-sky-view-factor-vital-balance-energetico-ciudades.html#:~:text=%C2%BFQu%C3%A9%20es%20el%20%22Sky%20View.urbano%20y%20del%20espacio%20p%C3%ABlico>
- [7] W. Pan and J. Du, "Effects of neighbourhood morphological characteristics on outdoor daylight and insights for sustainable urban design," Journal of Asian Architecture and Building Engineering.
<https://www.tandfonline.com/doi/full/10.1080/13467581.2020.1870472>
- [8] A. Tabadkani, A. Roetzel, H. X. Li, and A. Tsangrassoulis, "Daylight in Buildings and Visual Comfort Evaluation: the Advantages and Limitations," Journal of Daylighting <https://solarlits.com/jd/8-181>
- [9] J. Solawetz, "What is YOLOv8? A Complete Guide," Roboflow Blog, Nov. 11, 2025. <https://blog.roboflow.com/what-is-yolov8/>
- [10] J. Torres, "YOLOV8 Segmentation; Step-by-step explained - Yolov8," YOLOv8, Jan. 03, 2025. <https://yolov8.org/yolov8-segmentation/>

[11] J. Pedro, "Detailed Explanation of YOLOv8 Architecture — Part 1", Medium, Dec. 03, 2023. <https://medium.com/@juanpedro.bc22/detailed-explanation-of-yolov8-architecture-part-1-6da9296b954e>

[12] "Comparing YOLOv11 and YOLOv8 for instance segmentation of occluded and non-occluded immature green fruits in complex orchard environment." <https://arxiv.org/html/2410.19869v3>

[13] "Roboflow: Computer vision tools for developers and enterprises," Roboflow. <https://roboflow.com/>

[14] Ultralytics, "Performance Metrics Ultralytics YOLOV8 | MAP, F1 Score, Precision, IOU & Accuracy | EPISODE 25," YouTube. Feb. 09, 2024. [Online]. Available: <https://www.youtube.com/watch?v=q7LwPoM7tSQ>

[15] DigitalSreeni, "334 - Training custom instance segmentation model using YOLO v8," YouTube. Nov. 01, 2023. [Online]. Available: <https://www.youtube.com/watch?v=ytIhMAF6ok0>

[16] Aprendo Haciendo - Pérez, "Cómo Etiquetar Imágenes en Roboflow para Aprendizaje Automático," YouTube. Dec. 13, 2024. [Online]. Available: <https://www.youtube.com/watch?v=abWRKh6t56Y>